



Plan de Trabajo de Seminario Final

Licenciatura en Ciencia de Datos

Universidad Nacional Guillermo Brown (UNaB)

Título del tema de trabajo de Seminario Final

Modelado predictivo del sub-reporte de causa en incendios forestales de Estados Unidos (FPA-FOD, 1992–2015): un enfoque de clasificación binaria desbalanceada basado en perfil geográfico-institucional.

Integrante

Facundo Tarizzo, 44544123.

Objetivos Generales

Desarrollar un modelo de clasificación que estime la probabilidad de que un incendio forestal registrado en la base FPA-FOD quede sin causa de ignición reportada, identificando los factores geográficos, temporales e institucionales que explican este fenómeno de sub-reporte.

Objetivos Específicos

- Caracterizar la estructura del *missingness* de causa en la base FPA-FOD, evaluando su concentración geográfica (combinaciones Estado-Año) y su asociación con el tipo de agencia responsable del reporte (`NWCG_REPORTING_AGENCY`).
- Construir y validar temporalmente (entrenamiento 1992–2010, prueba 2011–2015) un modelo de clasificación binaria mediante *gradient boosting* (CatBoost) que prediga la probabilidad de sub-reporte de causa.
- Evaluar el aporte relativo de variables físicas del incendio (tamaño, estacionalidad) frente a variables administrativas (jurisdicción, agencia reportante, tendencia temporal) mediante análisis de importancia de variables.
- Contrastar los resultados obtenidos con antecedentes publicados sobre problemas de clasificación afines en esta misma base de datos, a fin de contextualizar el desempeño alcanzado.
- Discutir las implicancias metodológicas de este hallazgo para la confiabilidad de cualquier modelo de atribución directa de causa construido sobre esta base.

Antecedentes

La base FPA-FOD (*Fire Program Analysis Fire-Occurrence Database*), compilada por Karen Short para el Servicio Forestal de EE. UU., registra 1,88 millones de incendios forestales ocurridos entre 1992 y 2015, con información espacial, temporal, de magnitud y de jurisdicción para cada evento [1]. Del total de registros, el 8,9 % (166.723 incendios) no cuenta con causa de ignición reportada, categorizados como *Missing/Undefined*.

El abordaje inicial de este trabajo consistió en la clasificación directa de la causa de incendio mediante un esquema jerárquico en dos etapas (natural vs. antrópica, y causa específica dentro de las antrópicas), con validación temporal para evitar la sobreestimación de performance por autocorrelación espacio-temporal, un riesgo ampliamente documentado en la literatura de modelado predictivo sobre datos con estructura espacial y/o temporal [4]. Si bien la primera etapa alcanzó una performance aceptable (macro-F1 = 0,82), la segunda etapa se mantuvo en un macro-F1 de 0,37–0,39 pese a distintas estrategias de balanceo y ajuste de variables.

Este techo resultó consistente con trabajos publicados sobre el mismo problema. Pourmohamad et al. (2025), utilizando la versión ampliada del dataset (FPA FOD-Attributes) con aproximadamente 270 covariables ambientales, sociales y de manejo adicionales, lograron una exactitud del 93 % al separar causas naturales de antrópicas, pero de apenas 55 % al discriminar entre las 11 clases de causas humanas [2]. En la misma línea, Coffield et al. (2019), prediciendo tamaño final de incendio a partir de variables disponibles al momento de la ignición, reportan 50,4 % de exactitud en tres categorías de tamaño [3]. Estos antecedentes sugieren que el límite de performance no es atribuible al modelo o al enfoque metodológico, sino a la disponibilidad restringida de variables predictoras en la versión pública y reducida del dataset utilizada en este trabajo (sin enriquecimiento ambiental externo).

A partir del análisis exploratorio de los registros sin causa reportada, se identificó que su distribución no es aleatoria: se concentra en un subconjunto acotado de combinaciones Estado-Año (62 combinaciones con más del 80 % de *missingness*, que concentran el 60,6 % del total de registros sin causa) y está fuertemente asociada al tipo de agencia reportante —desde 0,03 % de *missingness* en reportes del Forest Service hasta 99,9 % en reportes de organizaciones interagenciales (*Interagency Organization*)—, según la documentación oficial de códigos de agencia del dataset [1]. Este hallazgo motivó el redireccionamiento del objeto de estudio hacia la pregunta que se desarrolla en este plan de trabajo.

Actividades y Metodología

- **Preparación de datos:** carga de la base FPA-FOD (formato SQLite) y construcción de la variable binaria objetivo (*ES_MISSING*), a partir de la columna *STAT_CAUSE_DESCR*.
- **Análisis exploratorio:** caracterización de la estructura geográfica y temporal del *missingness* mediante mapas de calor Estado×Año y tablas de contingencia por agencia reportante.
- **Ingeniería de variables:** construcción de variables de tasa histórica de *missingness* por Estado y por Agencia, calculadas exclusivamente sobre el período de entrenamiento (1992–2010) para evitar fuga de información hacia el período de prueba.
- **Modelado:** entrenamiento de un clasificador CatBoost con validación temporal, comparado contra un modelo de referencia (Random Forest) sobre las mismas variables.
- **Evaluación:** uso de métricas apropiadas para clasificación desbalanceada (AUC-ROC, AUC-PR / *average precision*), dado que la clase positiva representa el 8,9 % de los registros. Selección de umbral de decisión mediante maximización de F1 sobre la curva precisión-recall.

- **Interpretación:** análisis de importancia de variables (nativo de CatBoost) para determinar el peso relativo de factores físicos vs. administrativos.

Para el desarrollo se utiliza Python (pandas, scikit-learn, CatBoost) en el entorno Google Colab, con almacenamiento de la base de datos en Google Drive.

Factibilidad

- **Disponibilidad de los datos:** la base FPA-FOD está públicamente disponible (Kaggle, *1.88 Million US Wildfires*), ya descargada y almacenada en Google Drive.
- **Acceso a software especializado:** se cuenta con Python y las bibliotecas necesarias (CatBoost, scikit-learn) en Google Colab, con acceso a GPU (Tesla T4) para acelerar el entrenamiento.
- **Estado de avance:** el análisis exploratorio, la construcción de variables y un primer modelo ya se encuentran desarrollados; resta profundizar la validación de robustez y la redacción final del informe de tesis.
- **Presupuesto de tiempo:** redacción y cierre del documento final estimados en las semanas restantes hasta la fecha de entrega.

Referencias

- [1] Short, K. C. (2017). *Spatial wildfire occurrence data for the United States, 1992–2015 [FPA_FOD_20170508]* (4.^a ed.). Fort Collins, CO: Forest Service Research Data Archive. <https://databasin.org/datasets/dfb37cbc24b941fba26dbe139ecb7b53/>
- [2] Pourmohamad, Y., Abatzoglou, J. T., Fleishman, E., Short, K. C., Shuman, J., AghaKouchak, A., Williamson, M., Seydi, S. T., & Sadegh, M. (2025). Inference of wildfire causes from their physical, biological, social and management attributes. *Earth's Future*, 13(1). <https://agupubs.onlinelibrary.wiley.com/doi/10.1029/2024EF005187>
- [3] Coffield, S. R., Graff, C. A., Chen, Y., Smyth, P., Foufoula-Georgiou, E., & Randerson, J. T. (2019). Machine learning to predict final fire size at the time of ignition. *International Journal of Wildland Fire*, 28(11), 861–873. <https://connectsci.au/wf/article/28/11/861/21485/Machine-learning-to-predict-final-fire-size-at-the>
- [4] Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillerá-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913–929. <https://nsojournals.onlinelibrary.wiley.com/doi/10.1111/ecog.02881>